

Erkennen des Vorhandenseins von Sätzen mit Argumenten in kurzen Texten

Prokhar Navitski, 818431
Universität Potsdam 2024

Zusammenfassung

Das Argument-Mining ist eine der neuesten und komplexesten Aufgaben in der modernen Computerlinguistik. Die Bandbreite der Anwendungen in diesem Bereich ist ebenso breit wie die Vielfalt der Probleme, mit denen Experten in diesem Bereich konfrontiert sind. Obwohl die Herangehensweisen zur Lösung konkreter Aufgaben je nach Textgröße, Thema, Autorenperson und Kommunikationsmittel unterschiedlich sein können, werden fast alle auf der Erkennung von Text als argumentativ basieren, d. h. auf der Überprüfung und Erkennung von Teilen des Textes, in denen ein Argument vorliegt, das als Hauptdatentyp für weitere Arbeiten verwendet wird.

1 Einleitung

Das Ziel dieses Lehrprojekts besteht darin, die automatische Erkennung von Argumenten in Sätzen zu erforschen und das Modell dann auf kurze Texte anzuwenden. Die Ergebnisse sollen vorläufige Schlussfolgerungen darüber ermöglichen, wie das Modell effektiver trainiert werden kann, um Argumentation im Text zu erkennen, und potenziell Effektivität solcher Modelle in den realen Aufgaben aufzeigen.

2 Dataset

Die Datei enthält 700 Sätze, die aus ASR-Debatten zu kontroversen Themen extrahiert wurden. Ein Satz wird als positiv annotiert,

wenn er ein Argument zugunsten des festgelegten Themas enthält.¹

Jeder Satz wurde von drei professionellen Annotatoren annotiert. Die Sätze wurden mit Kontext präsentiert, und die Annotatoren mussten entscheiden, ob der Satz ein Argument enthält.

Den Annotatoren wurden folgende Richtlinien gegeben:

In der nächsten Aufgabe erhalten Sie einen Teil der Transkription einer mündlichen Debatte zu einem kontroversen Thema. Die Transkription wird oft automatisch erstellt und kann Fehler

¹Shnarch, E., Choshen, L., Moshkovich, G., Slonim, N., Aharonov, R. (2020). Unsupervised Expressive Rules Provide Explainability and Assist Human Experts Grasping New Domains. Findings of the Association for Computational Linguistics: EMNLP 2020.

enthalten (z. B. falsche Transkription von Wörtern oder schlechte Segmentierung von Sätzen).

Es wird ein Satz mit seinem Kontext in der Rede gegeben. Für diesen Satz müssen Sie feststellen, ob er ein Argument zugunsten des festgelegten Themas enthält.

Ein Argument ist ein Textausschnitt, der das festgelegte Thema direkt unterstützt oder in Frage stellt. Das Vorhandensein einer klaren Position zum Thema (für oder gegen) ist die wichtigste Bedingung dafür, dass der Text als Argument betrachtet wird.

3 Preprocessing

Bei der Vorverarbeitung der Sätze wurde nur eine grundlegende Verarbeitung durchgeführt, die das Umwandeln in Kleinbuchstaben und das Hinzufügen von Punkten am Ende der Sätze umfasste, da die Sätze im ursprünglichen Korpus ohne Satzzeichen am Ende aufgezeichnet wurden, was sich negativ auf die Generierung von Texten für eine der nächsten Arbeitsphasen des Projekts auswirken könnte.

Die Entfernung von Stoppwörtern und innerer Interpunktion in den Sätzen wurde nicht durchgeführt, da die Satzstruktur ein Indikator für das Vorhandensein eines Arguments im Satz sein kann und Stoppwörter Teil der lexikalischen Darstellung des Arguments sein können.

Das Modell wurde an einzelnen Sätzen trainiert, und erst danach wurde das Modell auf kurze Texte angewendet. Daher bestand keine Notwendigkeit für Tokenisierung, Lemmatisierung oder eine andere Form der Aufteilung der Sätze in Tokens, da das Modell selbst die Sätze miteinander verglich.

4 Feature extraction

Die beliebtesten Methoden zur Merkmalsextraktion aus Sätzen in englischer Sprache sind Bag of Words und TF-IDF (Term Frequency-Inverse Document Frequency). Aus Forschungsinteresse beschloss ich, das Modell ausschließlich mit TF-IDF zu trainieren, aus folgenden Gründen.

Bag of Words ist eine klassische Methode zur Merkmalsextraktion in der NLP, die Wörter als numerische Vektoren darstellt, jedoch die Häufigkeit der Wörter im Korpus insgesamt ignoriert und sich stattdessen auf die Häufigkeit innerhalb einzelner Texte konzentriert. Diese Methode dürfte für die Aufgabe dieses Forschungsprojekts kaum effektiv sein, da das Training auf einem Textkorpus erfolgt, der einzelne, nicht nach Themen sortierte Sätze enthält, sondern nur das Vorhandensein oder Fehlen eines Arguments, d. h. die Häufigkeitsvektoren in diesem Fall werden für den Korpus insgesamt nicht sehr repräsentativ sein, da der Korpus nicht einheitlich ist.

TF-IDF hingegen wandelt den Textkorpus (in diesem Fall einzelne Sätze) in numerische Merkmalsvektoren um, vergleicht dann, welche Vektoren am typischsten für Sätze sind, die das gesuchte Merkmal-Label enthalten (in diesem Fall das Vorhandensein eines Arguments), und bestimmt, welche Wörter in den Sätzen mit diesem Merkmal vorhanden sind. Anschließend bestimmt das Modell automatisch das Label des Satzes abhängig vom Vorhandensein dieser Vektoren. Das Prinzip ähnelt dem Bag of Words, jedoch besteht ein wichtiger Unterschied, der auf die potenzielle Effektivität dieser Methode zur Merkmalsextraktion hinweist, darin, dass sie

auch die Häufigkeit eines Wortes nicht nur in einem einzelnen Text des Korpus vergleicht, sondern im gesamten Korpus, was potenziell die Genauigkeit bei der Bestimmung charakteristischer Wörter für einen argumentativen Satz erhöht, selbst wenn die Texte des Korpus in verschiedenen Domänen liegen.

5 Modelling

Wie bereits in der Einleitung zu diesem Projekt erwähnt wurde, ist eine der ersten Aufgaben bei der Lösung von Problemen im Bereich Argument Mining fast immer die Bestimmung des Vorhandenseins eines Arguments im Satz oder im Text insgesamt.

Meine Idee besteht darin, das Modell darauf zu trainieren, das Vorhandensein argumentativer Sätze im Text zu erkennen. Dazu werde ich das Modell an einem Korpus von Sätzen trainieren, die von Experten auf das Vorhandensein von Argumenten in ihnen indexiert wurden. Nach dem Trainingsprozess plane ich, 1000 Texte mit jeweils 20 Sätzen zu generieren und die Anzahl der argumentativen Sätze mithilfe des Modells zu zählen.

Durch die Tatsache, dass die Texte aus Sätzen des Korpus generiert werden, werde ich die Möglichkeit haben, die tatsächliche Anzahl der Sätze, die von Experten als argumentativ gekennzeichnet wurden, mit der Anzahl der Sätze zu vergleichen, die das Modell als argumentativ kennzeichnet. Anschließend werde ich die Anzahl der Texte zählen, die tatsächlich die gleiche Anzahl argumentativer Sätze haben wie das Modell, sowie die Anzahl der Texte, die mehr oder weniger argumentative Sätze im Vergleich

zu den Annotationsergebnissen des Modells haben.

Daher besteht das Ziel dieses Projekts darin, das Modell für die Klassifizierung von Sätzen als argumentativ oder nicht argumentativ zu trainieren und statistisch die Übereinstimmung der Klassifizierungsergebnisse des Modells mit den Experten zu berechnen, die den Textkorpus erstellt haben, auf dem das Modell trainiert wurde. Da der Korpus nicht nach Domänen sortiert ist, gemäß den Themen der Texte, wird dies potenziell ermöglichen, die Möglichkeit der Verwendung dieses Modells zur Klassifizierung von Sätzen in Texten des allgemeinen Bereichs zu bewerten.

6 Training

Für das Training des Modells habe ich mich für eine Aufteilung von 80-20 entschieden, da der Korpus nur 700 Einträge umfasst. Daher wollte ich für eine genauere Kalibrierung des Modells so viele verfügbare Daten wie möglich nutzen.

Beim ersten Training des Modells zeigte es folgende Effizienz:

| | pre- cision | recall | f1- score | sup- port |
|---------------------|------------------------|---------------|----------------------|----------------------|
| 0 | 0.68 | 0.91 | 0.77 | 85 |
| 1 | 0.69 | 0.33 | 0.44 | 55 |
| accuracy | | | 0.68 | 140 |
| macro avg | 0.68 | 0.62 | 0.61 | 140 |
| weighted avg | 0.68 | 0.68 | 0.64 | 140 |

Tabelle 1: Die Tabelle der Metriken des Modells vor der Ausgleichung.

Jedoch wurde sofort klar, dass die Werte "re-

callünd "f-1 score" für beide Features zu stark unausgeglichen waren. Dies lag daran, dass die Daten im Korpus unausgeglichen waren und 275 Sätze mit einem Argument und 425 Sätze ohne ein Argument enthielten. Um den Korpus auszugleichen, habe ich einen neuen Korpus auf der Grundlage des Originals erstellt und 120 zufällige Sätze ohne Argument entfernt (diese wurden im Originalkorpus mit dem Label "0" markiert).

Nach dem Ausgleich verringerte sich die Größe des Korpus auf 550 Einträge, und das Modell zeigte folgende Ergebnisse beim Training mit einer Aufteilung von 80-20:

| | pre- cision | recall | f1- score | sup- port |
|---------------------|----------------|--------|--------------|--------------|
| 0 | 0.74 | 0.52 | 0.61 | 60 |
| 1 | 0.53 | 0.75 | 0.62 | 44 |
| accuracy | | | 0.62 | 104 |
| macro avg | 0.64 | 0.63 | 0.62 | 104 |
| weighted avg | 0.65 | 0.62 | 0.61 | 104 |

Tabelle 2: Die Tabelle der Metriken des Modells nach der Ausgleichung.

Beim Vergleich der Daten beider Tabellen wird deutlich, dass das Modell nach der Ausgleichung der Korpusdaten realistischere Genauigkeitsparameter aufweist. Es sollte jedoch erneut darauf hingewiesen werden, dass der ohnehin schon recht kleine Korpus mit 700 Einträgen nun auf einen Korpus mit 550 Einträgen reduziert wurde, was natürlich die Anwendbarkeit dieses Modells auf anderen Textkorpora einschränkt. Trotz der Vielseitigkeit des Textkorporus sind die statistischen Daten für genaue Schlussfolgerungen zur Effektivität des Modells

bei der Arbeit mit Texten außerhalb des im Projekt verwendeten Korpus sehr begrenzt.

7 Texts Generierung

Die Textgenerierung erfolgte unter Verwendung von Sätzen aus dem Originaltextkorpus. Es wurde auch eine Liste von IDs der beim Generieren verwendeten Sätze gespeichert. Diese wurden verwendet, um die Anzahl der Sätze im Originalkorpus zu zählen, die als argumentativ gekennzeichnet waren. Dies ermöglichte es, diese Zahl mit der Anzahl der Sätze zu vergleichen, die beim Einsatz des Modells in Bezug auf diesen Text als argumentativ markiert wurden. Alle Daten wurden zur Bequemlichkeit in einem .csv-Dokument gespeichert, das folgendes Format hatte:

| generated_corpus | | | |
|----------------------------------|----------------------------------|-------------|-----------------------|
| ids | texts | real number | assigned by the model |
| 219,82,366,345,455,488,249,36,21 | But we also just think if the gc | 9 | 8 |
| 294,337,68,34,450,305,456,82,24 | We tell you that ultimately, the | 8 | 12 |
| 348,162,423,216,351,129,67,320, | When the federal government | 11 | 12 |
| 134,155,350,216,151,396,488,51, | And second, we we think that | 9 | 9 |
| 330,513,483,418,20,4,481,211,67, | But additionally, we think this | 10 | 9 |
| 337,0,237,505,190,319,172,235,3, | The problem is that for centur | 11 | 13 |
| 496,358,50,14,216,387,511,447,4, | The reason why is that in a lib | 11 | 11 |
| 363,471,308,340,289,141,407,431 | First on rights record, people | 14 | 15 |
| 235,406,358,90,213,286,118,28,3, | So we understand the need f | 14 | 11 |
| 40,232,144,250,269,88,415,354,1 | We say that disbandment crei | 13 | 12 |

Abbildung 1: Beispiel für die Textgenerierung.

Neben zufällig generierten Texten habe ich auch versucht, Texte zu generieren, die ausschließlich aus argumentativen Sätzen oder nur aus Sätzen ohne Argument bestanden. Die Ergebnisse der Generierung solcher Texte wurden nicht zur Statistik herangezogen, aber selbst anhand solcher Texte ist offensichtlich, dass das Modell nicht sehr präzise ist, da die Unterschiede zwischen den Spalten der tatsächlichen An-

zahl argumentativer Sätze und der Anzahl der von der Modell bestimmten argumentativen Sätze recht häufig vorkommen. Im Rahmen des Experiments wurde nicht bewertet, wie stark sich die Zahlen in beiden Spalten unterscheiden.

| generated_corpus | | | |
|------------------------|--|-------------|-----------------------|
| ids | texts | real number | assigned by the model |
| 191,505,237,282,196,2 | This is the reason we live in the most peaceful time in hi | 20 | 17 |
| 438,454,518,31,202,34 | There will be no way for a musician or an author to pay i | 20 | 19 |
| 498,109,412,249,91,12 | I p because you can just take the l p from others and re | 20 | 19 |
| 118,5,36,478,390,291,1 | If the government bans cosmetic surgery, that's a massi | 20 | 16 |
| 229,340,518,289,63,41 | If you see cosmetic surgery is just a means by which me | 20 | 20 |
| 326,114,340,296,186,2 | So I want to talk about what's in avoids talking about in | 20 | 20 |
| 129,147,169,97,12,112 | I have two arguments in today's debate first, why it's pn | 20 | 19 |
| 471,162,285,0,269,15, | The nature of the internet is that no one country can reg | 20 | 19 |
| 436,202,300,295,509,4 | So we think at the point where government is confusing | 20 | 20 |
| 197,412,204,62,16,461 | And the reason for this is because I'm, if we want peopl | 20 | 20 |

Abbildung 2: Beispiel für die Generierung von Texten ausschließlich aus argumentativen Sätzen.

| generated_corpus | | | |
|---------------------------|--|--|--------------------------------------|
| ids | texts | real number of argumentative sentences | number of argumentative sentences as |
| 22,360,379,11,338,230,15 | So when we say we should lower th | 0 | 1 |
| 341,457,337,314,377,50,2 | We call this the anchoring effect thi | 0 | 1 |
| 37,130,450,363,207,48,42 | So what they had was a plurality of i | 0 | 1 |
| 201,154,351,386,346,500,0 | I don't think that this is necessarily s | 0 | 3 |
| 409,6,10,371,106,488,420 | So if a seventeen year old has sack | 0 | 1 |
| 171,3,35,494,365,154,222 | So there are a limited amount of inv | 0 | 4 |
| 181,443,342,393,418,395 | Some people may want to just run o | 0 | 1 |
| 491,174,416,338,160,374 | It means their access to clean water | 0 | 0 |
| 2,443,342,377,21,472,421 | We think that even if it makes it hard | 0 | 1 |
| 49,217,379,382,195,472,2 | And this is most true at these young | 0 | 2 |

Abbildung 3: Beispiel für die Generierung von Texten ausschließlich aus nicht-argumentativen Sätzen.

8 Ergebnisse

Als Ergebnisse des Projekts vergleiche ich, wie oft die Zählung der argumentativen Sätze im Text mit ihrer tatsächlichen Anzahl übereinstimmte.

Bei der Ausführung des Programms anhand von 1000 zufällig generierten Texten erhielt ich folgende Ergebnisse:




Abbildung 4: Die Ergebnisse der Bestimmung der Anzahl argumentativer Sätze in kurzen Texten mit Hilfe des TF-IDF-Modells.

Wie aus den Ergebnissen ersichtlich ist, hat unser Modell in etwas mehr als 50 Prozent der Fälle die Anzahl der argumentativen Sätze in den Texten korrekt bestimmt, was im Allgemeinen den Precision-Score für die Klasse "läus Tabelle 2 widerspiegelt. Jedoch können wir auch anhand des Diagramms feststellen, dass in den Fällen, in denen das Modell Fehler machte, es mehr als doppelt so oft eine höhere Anzahl von argumentativen Sätzen im Text bestimmte, verglichen mit der tatsächlichen Anzahl. Nur in etwa 15 Prozent der Fälle, in denen Texte durch das Modell gingen, wurden als solche erkannt, die weniger argumentative Sätze hatten, als tatsächlich vorhanden.

Wenn wir dieselbe Statistik für nicht-argumentative Sätze berechnen, wie erwartet ist die Statistik für nichtargumentative Sätze das Gegenstück zur Statistik für argumentative Sätze, was die Ergebnisse der ersten Zählung nur bestätigt. Würde sie wie folgt aussehen:




Abbildung 5: Die Ergebnisse der Bestimmung der Anzahl **nicht**-argumentativer Sätze in kurzen Texten mit Hilfe des TF-IDF-Modells.

9 Evaluation

Während der Arbeit an diesem Projekt musste ich viele Annahmen treffen: Es wurde keine Textvorverarbeitung durchgeführt, da die Texte zu kurz waren, um effektiv in Token aufgeteilt zu werden. Aufgrund der Verwendung des TF-IDF-Modells für die Merkmalsextraktion wurden keine Stoppwörter aus den Texten entfernt, da sie auch als Marker für das Vorhandensein eines Arguments dienen können. Der ursprünglich kleine Korpus musste weiter gekürzt werden, um eine bessere Datenbalance beim Training zu erreichen. Die kurzen Texte, die im Experiment verwendet wurden, wurden künstlich aus Sätzen des Korpus erstellt, da es nicht genügend Ressourcen für die manuelle Bewertung der Ergebnisse bei Verwendung zufälliger Texte gab.

Alle diese Annahmen wirken sich definitiv auf die Genauigkeit des Modells aus, da die TF-IDF-Merkmalsextraktion keine vektorbasierte Bewertung von Tokens und ihrer Be-

deutung in argumentativen Sätzen durchführt, sondern mit einzelnen Wörtern arbeitet, die in diesem Fall auch häufige Stoppwörter einschließen, was die Wahrscheinlichkeit erhöht, dass ein nicht-argumentativer Satz fälschlicherweise als argumentativ eingestuft wird, nur aufgrund der hohen Anzahl von Stoppwörtern. Dies spiegelt sich genau in den Ergebnissen in Abbildung 4 wider, wo wir sehen, dass bei fehlerhafter Bestimmung des Vorhandenseins eines Arguments im Satz dieser Satz häufiger als argumentativ eingestuft wurde.

Die Verkürzung des Korpus auf 550 Einträge von den ursprünglichen 700 spiegelt sich auch in der Repräsentativität der berechneten Wortvektoren wider, da das TF-IDF-Modell die Wortvektoren nicht nur in einzelnen Sätzen, sondern im gesamten Korpus berücksichtigt. Dadurch fällt es den Modellen schwerer, wenig bedeutsame Wörter für die Klasse zu identifizieren, aufgrund der geringen Vielfalt an Texten im Korpus.

Ein Nachteil der Anwendung des Modells auf Texte, die aus Sätzen generiert wurden, die zur Schulung dieses Modells verwendet wurden, besteht darin, dass die Ergebnisse wahrscheinlich nicht von den automatisch berechneten Modellleistungsmetriken abweichen werden, da das Modell im Grunde genommen zweimal auf denselben Datenlauf durchgeführt wurde. Die Einführung der Berechnung des Verhältnisses der tatsächlichen Anzahl argumentativer Sätze zu den Sätzen, die als argumentativ anhand des Modells identifiziert wurden, hilft jedoch dabei zu bestimmen, ob das Modell Sätze häufiger oder seltener als tatsächlich als argumentativ identifiziert. Diese Informationen sind äußerst nützlich, wenn ein solches Modell als

erster Schritt in einem umfangreichen Projekt im Bereich des Argument Mining verwendet wird, bei dem die Bestimmung argumentativer Sätze nur dazu dient, die Datenmenge zu reduzieren, mit der das Projekt anschließend arbeiten wird. Speziell mein Modell kann laut Berechnungen eine ziemlich signifikante prozentuale Zunahme der Sätze, die den argumentativen Kriterien entsprechen, hervorrufen, was wiederum das Datenpotenzial, das in einem Projekt verarbeitet werden muss, erheblich erhöht, wenn dieses Modell in einem seiner Schritte verwendet wird.

Es gibt jedoch auch einen ziemlich wichtigen positiven Aspekt des Projekts, der darin besteht, dass der Korpus nicht nach Domänen sortiert wurde. Dies könnte sich zwar zusätzlich auf die Genauigkeit des Modells auswirken, machte das Modell jedoch universeller und besser geeignet für eine breitere Domäne von Texten, die potenziell mit diesem Modell analysiert werden können, ohne die Angst vor Genauigkeitsverlust aufgrund von Domäneninkongruenz zu haben, auf der das Modell trainiert wurde.

10 Weitere Entwicklung

Das Wichtigste, was man bei der Arbeit an einem ähnlichen Projekt in Zukunft tun kann, ist die Verbesserung der Modellgenauigkeit. Dies kann auf verschiedene Arten erfolgen, je nachdem, mit welchen Daten das Modell während des Trainings und der Tests arbeiten wird. Jedoch könnten im oben beschriebenen Prozess folgende Schritte unternommen werden:

- **Schritt 1:** Das Trainingsdatenvolumen erhöhen, indem man manuell weitere 150 ar-

gumentative Sätze in den Korpus einfügt, um eine ausgewogenere Datenverteilung zugunsten der stärker vertretenen Klasse zu erreichen (425 nicht-argumentative Sätze).

- **Schritt 2:** Eine benutzerdefinierte Liste von Stoppwörtern erstellen, deren Entfernung die Argumentativität des Satzes sicher nicht beeinträchtigt, sondern die das Modell von "Rauschen" befreit, da unwichtige Funktionswörter entfernt werden und die Vektoren bereinigt werden.
- **Schritt 3:** Um die Aussagekraft der erhaltenen Daten im Teststadium zu erhöhen, sollten Texte verwendet werden, die nicht zur Modelltrainingsphase gehören. Dabei sollte die Anzahl der argumentativen Sätze in solchen Texten manuell gezählt werden, indem die Labels gemäß den im verwendeten Trainingskorpus vorgesehenen Richtlinien vergeben werden. Um die Repräsentativität zu erhöhen, sollten Texte unterschiedlicher Länge in die Stichprobe aufgenommen werden.

Mein persönliches Interesse an dieser Arbeit liegt in der Überprüfung der Effektivität des Modelltrainings an kleinen Textkorpora, da ich mit Low-Resource-Sprachen arbeiten möchte, die normalerweise über sehr begrenzte Korpora verfügen, die entweder überhaupt nicht indiziert oder nur teilweise indiziert sind.

Da das Sammeln und die qualitative Annotation großer Korpora ressourcenintensiv sein können (es werden große Teams, Ausrüstung und Finanzen benötigt), kann die Entwicklung effizienter Modelle, die auf kleinen Korpora

trainiert werden können, kleinen Teams oder sogar Einzelpersonen ermöglichen, die erforderliche Menge an Daten selbst zu sammeln und die Modelle anschließend anzuwenden.

Dieses Projekt ist genau ein Beispiel für den Versuch, ein solches Modell zu erstellen, da der Korpus des Projekts ursprünglich eine geringe Anzahl von Einträgen aufwies, während der Arbeit am Projekt verkürzt wurde und die Texte darin nicht nach Domänen sortiert wurden, was darauf hindeutet, dass solche Trainingsmethoden auf Modelle angewendet werden können, die mit cross-domain Texten arbeiten.

Education "Vyatka State University", Kirov Region]. Russian Science Foundation. (<https://github.com/dialogue-evaluation/RuArg/blob/main/README.md> **2022**; <https://github.com/kotelnikov-ev/RuArgumentMining?tab=readme-over-file> **2023**).

Literatur

- [1] Shnarch, E., Choshen, L., Moshkovich, G., Slonim, N., Aharonov, R. "Unsupervised Expressive Rules Provide Explainability and Assist Human Experts Grasping New Domains." Findings of the Association for Computational Linguistics: EMNLP 2020.
- [2] Eskandar, Sahel. "Exploring Feature Extraction Techniques for Natural Language Processing." Medium, 26 Apr. 2023, <https://medium.com/@eskandar.sahel/exploring-feature-extraction-techniques-for-natural-language-processing-46052ee6514>.
- [3] Kotelnikov, E. V. (2022-2023). Development and investigation of a method for generating argumentative texts (Publication No. 22-21-00885) [Doctoral dissertation, Federal State Budgetary Educational Institution of Higher